Tarea C — Temas latentes con LDA en un corpus mínimo (Blei, Ng y Jordan, 2003)

Objetivo

Aplicar Latent Dirichlet Allocation (LDA) al corpus de doce oraciones del curso (cuatro de deporte, cuatro de cocina y cuatro de astronomía) para: (1) ajustar un modelo de tres temas y describir los temas latentes; (2) comparar la perplejidad de modelos con 2, 3 y 4 temas; (3) evaluar si los temas latentes recuperan las etiquetas reales mediante la pureza; y (4) discutir, con base en Blei et al. (2003), qué añade LDA frente a pLSI y por qué un corpus de doce oraciones es un mal escenario para LDA. En ninguna parte el modelo observa la columna «tema».

Método

- **Vectorización.** `CountVectorizer` con la lista de palabras vacías del enunciado (el, la, los, las, de, del, en, y, a, un, una, por, para, con, se, su, al, es, después, durante, contra, donde, alrededor) y el resto de parámetros por defecto. El vocabulario resultante tiene 71 términos y es idéntico en todas las partes.
- **Modelo.** `LatentDirichletAllocation(n_components=k, learning_method="batch", max_iter=50, random_state=0)`, con k=3 en las Partes 1 y 3, y $k \in \{2, 3, 4\}$ en la Parte 2, usando el mismo vectorizador.
- **Perplejidad.** Se reporta la perplejidad de cada modelo sobre el propio corpus.
- **Pureza (Parte 3).** Cada documento se asigna a su tema dominante; para cada tema de LDA se cuenta la etiqueta real más frecuente entre sus documentos; la pureza es la suma de esas cuentas dividida por 12.
- **Parte 4.** Discusión conceptual apoyada en Blei, Ng y Jordan (2003).

Resultados

Parte 1 — LDA con tres temas

Vocabulario: 71 términos. Perplejidad del modelo (k=3) sobre el corpus: 137.7877.

Tema	Cinco palabras más probables
tema_1	órbita, planetas, partido, minutos, huevos
tema_2	equipo, partido, liga, ganó, dos
tema_3	sal, nebulosa, galaxia, estrellas, ajo

Los temas no corresponden limpiamente a los tres temas reales: tema_1 mezcla astronomía con deporte y cocina, y tema_3 mezcla cocina con astronomía.

Parte 2 — Perplejidad según el número de temas

Número de temas (k)	Perplejidad
2	107.8909
3	137.7877
4	156.4198

El mejor k según la perplejidad sobre el corpus es 2. La perplejidad con k=3 coincide exactamente con la de la Parte 1 (diferencia 0.0), lo que confirma la reproducibilidad de la ejecución.

Parte 3 — Asignación por documento y pureza

id	Etiqueta real	Tema dominante (LDA)	p(tema dominante)	Bien agrupado
d01	deporte	tema_2	0.9320	sí
d02	deporte	tema_1	0.9005	no
d03	deporte	tema_1	0.8985	no

d04	deporte	tema_2	0.9157	sí
d05	cocina	tema_1	0.9294	no
d06	cocina	tema_1	0.9135	no
d07	cocina	tema_3	0.9236	no
d08	cocina	tema_3	0.9378	no
d09	astronomía	tema_3	0.9155	sí
d10	astronomía	tema_1	0.9160	sí
d11	astronomía	tema_3	0.9162	sí
d12	astronomía	tema_1	0.9149	sí

Composición de los temas: tema_1 agrupa a d02, d03, d05, d06, d10 y d12 (2 deporte, 2 cocina, 2 astronomía; mayoría «astronomía», 2/6); tema_2 agrupa a d01 y d04 (ambos de deporte); tema_3 agrupa a d07, d08, d09 y d11 (2 cocina y 2 astronomía; mayoría «astronomía», 2/4).

Pureza = 6/12 = 0.5. Quedan mal agrupados seis documentos: d02 y d03 (deporte, asignados a tema_1), d05 y d06 (cocina, asignados a tema_1) y d07 y d08 (cocina, asignados a tema_3). LDA no ve las etiquetas reales y los índices de sus temas son arbitrarios; los fallos provienen del vocabulario compartido entre temas.

Discusión

Qué añade LDA frente a pLSI. En pLSI el documento d es un índice ficticio de los documentos de entrenamiento: el modelo aprende p(z|d) solo para esos documentos, de modo que «pLSI no es un modelo generativo bien definido de documentos» y «no hay una forma natural de usarlo para asignar probabilidad a un documento no visto» (Blei et al., 2003, p. 9). Además, sus parámetros crecen linealmente con el número de documentos (kV + kM), lo que lo hace propenso al sobreajuste. LDA añade un prior de Dirichlet sobre las proporciones de tema de cada documento dentro del proceso generativo (elegir N ~ Poisson(ξ), elegir θ ~ Dir(α) y, para cada palabra, un tema y luego la palabra): cada documento es una mezcla aleatoria de temas, el número de parámetros no crece con el corpus y un documento nuevo recibe sus propias proporciones de tema sin necesidad de heurísticas de plegado («folding-in») como la que propone Hofmann y que Blei et al. describen como una ventaja injusta al reajustar parámetros sobre los datos de prueba (p. 20). Blei et al. señalan también que pLSI sobreajusta al crecer k porque obliga a que todo documento nuevo exhiba proporciones de tema ya vistas en el entrenamiento, problema del que LDA no adolece (p. 20).

Por qué doce oraciones son un mal escenario para LDA. Con 12 documentos muy cortos y un vocabulario de 71 términos, las estadísticas de coocurrencia son demasiado escasas para estimar distribuciones tema–palabra fiables, y el vocabulario compartido entre temas («partido», «ganó», «dos» en deporte; «sal» y «ajo» en cocina) difumina las fronteras: de ahí que tema_1 mezcle los tres temas reales y que la pureza sea solo 0.5. La perplejidad, calculada sobre el mismo corpus de entrenamiento, premia los modelos más simples: el mejor k es 2 (107.8909) aunque el corpus tiene tres temas reales, y la perplejidad crece con k (137.7877 con k=3; 156.4198 con k=4). En un corpus mínimo, ni el criterio de perplejidad ni las palabras más probables recuperan la estructura latente verdadera; LDA está concebido para colecciones grandes, donde el prior de Dirichlet y el modelo generativo para documentos nuevos aportan ventajas que aquí no llegan a materializarse.