Tarea C — Temas latentes con LDA en un corpus mínimo

Objetivo

Aplicar Latent Dirichlet Allocation (LDA; Blei, Ng y Jordan, 2003) a un corpus mínimo de doce oraciones de tres temas reales (deporte, cocina y astronomía), sin usar las etiquetas durante el ajuste. Las metas son: (1) ajustar un modelo de tres temas y reportar el tamaño del vocabulario, las cinco palabras más probables por tema y la perplejidad; (2) comparar la perplejidad con 2, 3 y 4 temas; (3) comprobar si LDA recupera los temas reales mediante la asignación del tema dominante y la pureza; y (4) discutir qué añade LDA frente a pLSI y por qué un corpus de doce oraciones es un mal escenario para este modelo.

Método

Datos y vectorización. Se usaron las doce oraciones del enunciado (cuatro por tema); la columna «tema» se reservó exclusivamente para la evaluación de la Parte 3 y no se descargó ningún corpus externo. Los textos se vectorizaron con `CountVectorizer` y la lista de palabras vacías del enunciado (el, la, los, las, de, del, en, y, a, un, una, por, para, con, se, su, al, es, después, durante, contra, donde, alrededor), con el resto de parámetros por defecto. El vocabulario resultante tiene 71 términos y es el mismo en todas las partes.

Modelo y evaluación. Se ajustó `LatentDirichletAllocation(n_components=3, learning_method="batch", max_iter=50, random_state=0)`. Para la Parte 2 se reutilizó el mismo vectorizador y los mismos parámetros con 2, 3 y 4 componentes. Para la Parte 3 se asignó a cada documento su tema dominante (mayor probabilidad documento–tema) y se calculó la pureza: para cada tema de LDA se contó la etiqueta real más frecuente entre sus documentos, se sumaron esas cuentas y se dividió entre 12. Todas las cifras del reporte provienen de la ejecución.

Resultados

Parte 1 — LDA con tres temas

Tema	Cinco palabras más probables
0	órbita, planetas, partido, minutos, huevos
1	equipo, partido, liga, ganó, dos
2	sal, nebulosa, galaxia, estrellas, ajo

Vocabulario: 71 palabras. Perplejidad del modelo de 3 temas sobre el corpus: 137.7877.

Parte 2 — Perplejidad según el número de temas

k	Perplejidad
2	107.8909
3	137.7877
4	156.4198

Parte 3 — Asignación por documento y pureza

id	Etiqueta real	Tema dominante	p(doc·tema) [t0, t1, t2]	Bien agrupado
d01	deporte	1	[0.0345, 0.9320, 0.0335]	sí
d02	deporte	0	[0.9005, 0.0575, 0.0420]	sí
d03	deporte	0	[0.8985, 0.0536, 0.0480]	sí
d04	deporte	1	[0.0425, 0.9157, 0.0418]	sí

d05	cocina	0	[0.9294, 0.0337, 0.0368]	no
d06	cocina	0	[0.9135, 0.0422, 0.0443]	no
d07	cocina	2	[0.0390, 0.0374, 0.9236]	sí
d08	cocina	2	[0.0316, 0.0306, 0.9378]	sí
d09	astronomía	2	[0.0425, 0.0420, 0.9155]	no
d10	astronomía	0	[0.9160, 0.0421, 0.0420]	no
d11	astronomía	2	[0.0419, 0.0420, 0.9162]	no
d12	astronomía	0	[0.9149, 0.0421, 0.0430]	no

Pureza: 0.5 (6 de 12 documentos bien agrupados). Mal agrupados: d05, d06, d09, d10, d11 y d12. Composición de los temas: el tema 0 reunió 2 deporte, 2 cocina y 2 astronomía (etiqueta mayoritaria «deporte»); el tema 1, 2 deporte; el tema 2, 2 cocina y 2 astronomía (etiqueta mayoritaria «cocina»).

Discusión

Recuperación de los temas. LDA no reconstruyó los tres temas reales: la pureza fue 0.5. La causa se ve en las palabras de la Parte 1: el tema 0 mezcla vocabulario de astronomía (órbita, planetas) con palabras de deporte y cocina (partido, minutos, huevos), y el tema 2 mezcla cocina (sal, ajo) con astronomía (nebulosa, galaxia, estrellas). Así, d05 y d06 (cocina) caen en el tema 0 por «huevos» y «minutos»; d10 y d12 (astronomía) caen en el tema 0 por «órbita» y «planetas»; y d09 y d11 (astronomía) caen en el tema 2, de mayoría cocina, por «nebulosa», «galaxia» y «estrellas». Con doce oraciones cortas y un vocabulario de 71 términos casi hapax, las coocurrencias son demasiado escasas para que la verosimilitud separe los temas y la posterior queda dominada por el prior. Además, la perplejidad de la Parte 2 decrece al reducir k (107.8909 con 2 temas frente a 137.7877 con 3 y 156.4198 con 4): ese criterio, medido sobre el mismo corpus de entrenamiento, preferiría 2 temas aunque el corpus tiene 3 temas reales, de modo que no es un buen selector del número de temas en este escenario.

Qué añade LDA frente a pLSI. Según Blei, Ng y Jordan, 2003, en pLSI el documento es un índice ficticio de la lista de entrenamiento: las proporciones de tema se aprenden solo para los documentos vistos, el número de parámetros crece linealmente con el número de documentos y el modelo sobreajusta; además, pLSI no es un modelo generativo bien definido y no hay forma natural de asignar probabilidad a un documento nuevo, salvo la heurística de «folding-in» de Hofmann, que reajusta parámetros sobre los datos de prueba. LDA añade un prior de Dirichlet sobre las proporciones de tema dentro de un proceso generativo completo (elegir las proporciones de tema del documento y luego generar cada palabra desde su tema): cualquier documento nuevo recibe su propia mezcla de temas sin parámetros adicionales, lo que evita el sobreajuste ligado al tamaño del conjunto y permite evaluar perplejidad en datos no vistos.

Por qué doce oraciones son un mal escenario. El prior de Dirichlet y la inferencia de LDA presuponen muchos documentos de longitud razonable para estimar tanto las distribuciones palabra–tema como la variabilidad de las mezclas. Con doce oraciones, cada palabra aparece en uno o dos documentos, la evidencia empírica es mínima frente al prior y los resultados (asignaciones, pureza y perplejidad) dependen fuertemente de la semilla (`random_state=0`) y del número de iteraciones (50). El experimento ilustra el mecanismo del modelo, no su comportamiento estadístico en régimen.